

Demo Open Refine

Cours open data - Ministère de la Culture

Dataactivist - Anne-Laure Donzel

2025-09-12

Charger un fichier

Charger le fichier, plusieurs format sont acceptés.

 **OpenRefine** *A power tool for working with messy data.*

New Version [Download](#)

Create Project
Open Project
Import Project
Language Settings

Create a project by importing data. What kinds of data files can I import?

TSV, CSV, *SV, Excel (.xls and .xlsx), JSON, XML, RDF as XML, and Google Data documents are all supported.

Get data from

This Computer
Web Addresses (URLs)
Clipboard
Database
Google Data

Locate one or more files on your computer to upload:

Parcourir... demo_open_refine.ods

Next »

Sélectionner les options et créer le projet

Suivant les cas : choix du séparateur, de l'encodage, de l'en-tête... puis créer le projet.

 **OpenRefine** *A power tool for working with messy data.*

New Version [Download OpenRefine v3.5.2 now.](#)

Create Project
Open Project
Import Project
Language Settings

« Start Over » Configure Parsing Options

Project name: demo_open_refine.ods Tags:

Create Project »

	Commune	INSEE	Région	Département	Commune 1	Appellation courante	Adresse 1	Siècle	Date de protection	Auteur	statut	Historique	Affectataire	Référence	Column	Column 1
1.	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Marseille	Immeuble dit Maison du Figaro	1 cours Saint-Louis ; la Canebière	4e quart 17e siècle	1949/12/06 : inscrit MH	PAVILLON Pierre (architecte)	propriété d'une association			PA00081361		
2.	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Marseille	Grotte-ermitage des Ayalades ou des Carmes			1992/08/31 : classé MH ; 1994/09/02 : inscrit MH		propriété de l'Etat ; propriété privée	Une des premières implantations des Carmes en France. Rareté de l'architecture monastique troglodytique.	ministère chargé de l'équipement et du logement	PA00081517		
3.	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Marseille	Maison dite de l'Echevin de Cabre	Grande-Rue 85	16e siècle	1926/11/02 : inscrit MH ; 1941/05/02 : classé MH		propriété privée			PA00081363		
4.	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Marseille	Ancien atelier Nadar	77 La Canebière	4e quart 19e siècle	2012/02/20 : inscrit MH		propriété d'une société privée	Seul atelier de Nadar subsistant et seul studio de photographie		PA13000075		

Parse data as

Open Document Format spreadsheets (.ods)
XML files
JSON files
Line-based text files
CSV / TSV / separator-based files

Worksheets to Import

Select All Unselect All

☒ demo_open_refine.ods#Feuille1

96 rows

☐ Ignore first line(s) at beginning of file
☒ Parse next line(s) as column headers
☐ Discard initial row(s) of data
☐ Load at most row(s) of data

☒ Store blank rows
☒ Store blank cells as nulls
☐ Store file source (file names, URLs) in each row

Update Preview

Version 3.4.1 (437dcd4)

Les facettes

Le contenu de chaque colonne peut être visualiser sous la forme de facette. Test sur la facette *Commune* : changer la valeur blank

OpenRefine demo_open_refine ods [Permalink](#)

Facet / Filter Undo / Redo 0 / 0

Refresh Reset All Remove All

96 rows

Show as: rows records Show: 5 10 25 50 rows

Commune 1 change

1 choices Sort by: name count Cluster

Marseille 95 (blank) 1

Facet by choice counts

	All	Commune	INSEE	Région	Département	Commune 1	Appellation cour	Adresse 1	Siècle	Date de protecti	Auteur	st	
1.	★	★	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Facet	Text facet	e quart	1949/12/06 : inscrit MH	PAVILLON Pierre (architecte)	proprié	d'une assoc	
2.	★	★	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Text filter	Numeric facet		1992/08/31 : classé MH ; 1994/09/02 : inscrit MH		proprié	de l'Et	
3.	★	★	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Edit cells	Timeline facet					proprié	privée
4.	★	★	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Edit column	Scatterplot facet						
						Transpose	Custom text facet...						
						Sort...	Custom Numeric Facet...						
						View	Customized facets						
						Reconcile							

Changer une valeur

Faire une facette sur *Affectataire* : changer la Direction Générale du Patrimoine en Ministère de la Culture

Méthode 1 : en modifiant la valeur dans la fenêtre des facettes (*edit*)

OpenRefine demo_open_refine ods [Permalink](#)

Facet / Filter Undo / Redo 2 / 2

Refresh Reset All Remove All

95 rows

Show as: rows records Show: 5 10 25 50 rows

Affectataire change

8 choices Sort by: name count Cluster

direction générale des patrimoines 2

ministère chargé de l'équipement 2

ministère chargé de l'équipement et du logement 2

ministère chargé de l'intérieur 1

ministère chargé de la culture 2

ministère chargé de la défense 2

ministère chargé de la défense ; direction générale des patrimoines 1

ministère de l'écologie, du développement durable et de l'énergie 1

direction générale des patrimoines

Apply Enter Cancel Esc

ent	Commune 1	Appellation cour	Adresse 1	Siècle	Date de pro
Marseille	Immeuble dit Maison du Figaro	1 cours Saint-Louis ; la	4e quart 17e siècle	1949/12/06 : insc MH	
					1992/08/31 : clas MH ; 1994/09/02 inscrit MH
Marseille	Maison dite de l'Echevin de Cabre	Grande-Rue 85	16e siècle	1926/11/02 : insc MH ; 1941/05/02 classé MH	
Marseille	Ancien atelier Nadar	77 La Canebière	4e quart 19e siècle	2012/02/20 : insc MH	

Méthode 2 : en sélectionnant la colonne, *edit cells* et *replace*, permet de faire le changement grâce à un chercher-replacer

acteur	statut	Historique	Affectataire	Référence	Column	Column 16
ON	propriété d'une association		Facet	81361		
ecte)	propriété de l'Etat ; propriété privée	Une des premières implantations des Carmes en France. Rareté de l'architecture monastique troglodytique.	Text filter	81517		
	propriété privée		Edit cells			
	propriété d'une société privée	Seul atelier de Nadar subsistant et seul studio de photographe professionnel du 19e siècle	Edit column	PA130		
			Transpose			
			Sort...			
			View			
			Reconcile			

Méthode 3 : par une expression régulière, *edit cells*, *transform* puis saisir > `value.replace("direction générale des patrimoines", "Ministère de la Culture")`

OpenRefine demo_open_refine ods Permalink

Filter Undo / Redo 8 / 8 95 rows

Custom text transform on column Affectataire

Expression Language General Refine Expression Language (GREL) No syntax error.

`value.replace("direction générale des patrimoines", "Ministère de la Culture")`

Preview History Starred Help

row	value	value.replace("direction génér ...
1.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string
2.	ministère chargé de l'équipement et du logement	ministère chargé de l'équipement et du logement
3.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string
4.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string
5.	direction générale des patrimoines	Ministère de la Culture
6.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string
7.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string

On error ☒ keep original ☐ set to blank ☐ store error ☐ Re-transform up to 10 times until no change

OK Cancel

Méthode 4 : par du rapprochement sémantique. Pour cela il faut choisir une autre colonne, par exemple *commune*

Séparer des colonnes

Choisir la colonne *Date de protection*, *split into several columns* et choisir les paramètres. Ne garder que la date dans la colonne.

Changer le type de champ

La colonne date peut être transformée en une véritable colonne de date : choisir la colonne, *edit cells, commons transforms, to date*

ls Show: 5 10 25 50 rows

Siècle	Date de protection	Type protection	Date de protection	Date de protection	Auteur	statut	Historique	
4e quart 17e siècle	Facet Text filter	scrit MH			PAVILLON Pierre (architecte)	propriété d'une association		
	Edit cells Edit column Transpose Sort... View Reconcile	Transform... Common transforms Fill down Blank down Split multi-valued cells... Join multi-valued cells... Cluster and edit... Replace	scrit			propriété de l'Etat ;	Une des premières implantations des Carmes en France. Rareté de l'architecture monastique troglodytique.	minis de l'é et du
16e siècle								
4e quart 19e siècle	2012/02/20	in					Seul atelier de Nadar subsistant et seul studio de photographe professionnel du 19e siècle connu en France à ce jour. Au terme d'une carrière parisienne de 40 ans et suite à une mésentente avec son fils Paul, Nadar (Gaspard Félix Tournachon 1820-1910 dit)	

Supprimer des espaces

Lors des changements précédents des espaces sont apparus en tête de champ, ils peuvent être supprimés : *edit cells*, *Trim leading and trailing whitespace*

Aller plus loin avec Open Refine

Open Refine peut appeler l'API de Wikidata, la base de données en web sémantique de Wikimedia. Il est ainsi possible de récupérer des éléments de Wikidata.

Par exemple, notre fichier comprend, pour certains monuments, un auteur. Si ces auteurs existent sur Wikidata, il est possible de rapatrier des informations, par exemple leur lieu de naissance.

Cette opération s'appelle une *réconciliation* de données.

Réconciliation des auteurs

Choisir la colone puis *reconcile*, *start reconciling* ajouter le service de réconciliation français

https://wikidata.reconci.link/fr/api (https://wikidata.reconci.link/fr/api)

de protectio	Type protection	Auteur	statut	Historique	Affectataire	Référence
06T00:00:00Z	inscrit MH	Facet Text filter				PA00081361
01T00:00:00Z	classé MH	Edit cells Edit column Transpose Sort... View		Une des premières implantations des Carmes en France. Rareté de l'architecture monastique troglodytique.	ministère chargé de l'équipement et du logement	PA00081517
02T00:00:00Z	inscrit MH	Reconcile		Start reconciling...		PA00081363
00T00:00:00Z	inscrit MH		propriété d'une société privée	Facets Actic Copy reconciliation data... Use values as identifiers Add entity identifiers column		PA13000075
				d'une carrière parisienne de 40 ans et suite à une		

La réconciliation porte sur des être humains, *start reconciling*

Reconcile column "Auteur"

» Access [Service API](#)

Reconcile each cell to an entity of one of these types:

☒ être humain
Q5

Also use relevant details from other columns:

Column	Include?	As Property
Commune	☐	
INSEE	☐	
Région	☐	
Département	☐	
Commune 1	☐	
Appellation courante	☐	
Adresse 1	☐	
Siècle	☐	
Date de protection 1 1	☐	
Type protection	☐	
statut	☐	
Historique	☐	

☐ Reconcile against type:
☐ Reconcile against no particular type
☒ Auto-match candidates with high confidence

Maximum number of candidates to return

Le système a fait le lien entre notre fichier et Wikidata, il propose une correspondance (matching), si cela correspond bien il faut le valider.

Auteur	statut	Historique	Affectataire	Référence	Column
PAVILLON Pierre (architecte) edit	propriété			PA00081361	

☒ [Pierre Pavillon](#) (73)
☒ Create new item
[Search for match](#)

[Pierre Pavillon](#) (Q15409315)
 architecte français



Alors ?

La qualité de la colonne ne permet pas de faire une bonne réconciliation.

Réconciliation à partir d'un identifiant

Tentons la réconciliation sur une autre colonne : *Référence*. Wikidata intègre de nombreux référentiel dont celui sur les identifiants des monuments historiques.

17 matching rows (95 total)

Show

ie

199

Reconcile column "Référence"

» Access [Service API](#)

Reconcile each cell to an entity of one of these types:

- ☐ maison
Q3947
- ☐ chapelle
Q108325
- ☐ château
Q751876
- ☐ cathédrale catholique
Q56242215
- ☐ immeuble
Q11755959
- ☐ église
Q16970
- ☐ grotte
Q35509
- ☐ atelier
Q656720
- ☐ forteresse
Q57831

Also use relevant details from other columns:

Column	Include?	As Property
Commune	☐	
INSEE	☐	
Région	☐	
Département	☐	
Commune 1	☐	
Appellation courante	☐	
Adresse 1	☐	
Siècle	☐	
Date de protection 1 1	☐	
Type protection	☐	
Auteur	☐	
statut	☐	

☒ Reconcile against type:

☐ Reconcile against no particular type

☒ Auto-match candidates with high confidence

Maximum number of candidates to return

Add Standard Service...

Start Reconciling Cancel

1996-10-03T00:00:00Z inscrit MH REY Sixte (architecte) propriété d'une Edifice construit pour le PA13000010

☒ Create new item

Cette fois cela fonctionne mieux, on peut ensuite récupérer les coordonnées géographiques des monuments, *add columns, add columns from reconciled values*

identifiant d'une personne ou d'une organisation sur le site web du G

VIEILLE CHAÎNE

et réussit à en faire le rendez-