

Demo Open Refine

Cours open data - Ministère de la Culture

Dataactivist - Anne-Laure Donzel

2025-09-19

Charger un fichier

Charger le fichier, plusieurs format sont acceptés.

 **OpenRefine** *A power tool for working with messy data.*

New Version [Download](#)

Create Project

Open Project

Import Project

Language Settings

Create a project by importing data. What kinds of data files can I import?

TSV, CSV, *SV, Excel (.xls and .xlsx), JSON, XML, RDF as XML, and Google Data documents are all supported.

Get data from

This Computer

Web Addresses (URLs)

Clipboard

Database

Google Data

Locate one or more files on your computer to upload:

Parcourir... demo_open_refine.ods

Next »

Sélectionner les options et créer le projet

Suivant les cas : choix du séparateur, de l'encodage, de l'en-tête...puis créer le projet.

 **OpenRefine** *A power tool for working with messy data.*

New Version [Download OpenRefine v3.5.2 now.](#)

Create Project

Open Project

Import Project

Language Settings

« Start Over » Configure Parsing Options

Project name: demo_open_refine.ods Tags:

Create Project »

	Commune	INSEE	Région	Département	Commune 1	Appellation courante	Adresse 1	Siècle	Date de protection	Auteur	statut	Historique	Affectataire	Référence	Column	Column 1
1.	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Marseille	Immeuble dit Maison du Figaro	1 cours Saint-Louis ; la Canebière	4e quart 17e siècle	1949/12/06 : inscrit MH	PAVILLON Pierre (architecte)	propriété d'une association			PA00081361		
2.	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Marseille	Grotte-ermitage des Ayalades ou des Carmes			1992/08/31 : classé MH ; 1994/09/02 : inscrit MH		propriété de l'Etat ; propriété privée	Une des premières implantations des Carmes en France. Rareté de l'architecture monastique troglodytique.	ministère chargé de l'équipement et du logement	PA00081517		
3.	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Marseille	Maison dite de l'Echevin de Cabre	Grande-Rue 85	16e siècle	1926/11/02 : inscrit MH ; 1941/05/02 : classé MH		propriété privée			PA00081363		
4.	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Marseille	Ancien atelier Nadar	77 La Canebière	4e quart 19e siècle	2012/02/20 : inscrit MH		propriété d'une société privée	Seul atelier de Nadar subsistant et seul studio de photographie		PA13000075		

Parse data as

Open Document Format spreadsheets (.ods)

XML files

JSON files

Line-based text files

CSV / TSV / separator-based files

Worksheets to Import

Select All Unselect All

☒ demo_open_refine.ods#Feuille1

96 rows

☐ Ignore first

☒ Parse next

☐ Discard initial

☐ Load at most

0 line(s) at beginning of file

1 line(s) as column headers

0 row(s) of data

0 row(s) of data

☒ Store blank rows

☒ Store blank cells as nulls

☐ Store file source (file names, URLs) in each row

Update Preview

Version 3.4.1 (437dcd4)

Les facettes

Le contenu de chaque colonne peut être visualiser sous la forme de facette. Test sur la facette *Commune* : changer la valeur blank

OpenRefine demo_open_refine ods [Permalink](#)

Facet / Filter Undo / Redo 0 / 0

Refresh Reset All Remove All

Commune 1 change
1 choices Sort by: name count Cluster
Marseille 95
(blank) 1
Facet by choice counts

96 rows
Show as: rows records Show: 5 10 25 50 rows

	All	Commune	INSEE	Région	Département	Commune 1	Appellation cour	Adresse 1	Siècle	Date de protecti	Auteur	st
1.	★	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Facet	Text facet	e quart	1949/12/06 : inscrit MH	PAVILLON Pierre (architecte)	proprié	d'une assoc
2.	★	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Text filter	Numeric facet		1992/08/31 : classé MH ; 1994/09/02 : inscrit MH		proprié	de l'Et
3.	★	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Edit cells	Timeline facet					proprié
4.	★	Marseille	13055	Provence-Alpes-Côte d'Azur	Bouches-du-Rhône	Edit column	Scatterplot facet					proprié
						Transpose	Custom text facet...					privée
						Sort...	Custom Numeric Facet...					
						View	Customized facets					
						Reconcile	Reconcile					
							Ancien atelier Nadar	77 La Canebière	4e quart 19e siècle	2012/02/20 : inscrit MH		proprié

Changer une valeur

Faire une facette sur *Affectataire* : changer la Direction Générale du Patrimoine en Ministère de la Culture

Méthode 1 : en modifiant la valeur dans la fenêtre des facettes (*edit*)

OpenRefine demo_open_refine ods [Permalink](#)

Facet / Filter Undo / Redo 2 / 2

Refresh Reset All Remove All

Affectataire change
8 choices Sort by: name count Cluster

direction générale des patrimoines 2
ministère chargé de l'équipement 2
ministère chargé de l'équipement et du logement 2
ministère chargé de l'intérieur 1
ministère chargé de la culture 2
ministère chargé de la défense 2
ministère chargé de la défense ; direction générale des patrimoines 1
ministère de l'écologie, du développement durable et de l'énergie 1

direction générale des patrimoines

Apply Enter Cancel Esc

95 rows
Show as: rows records Show: 5 10 25 50 rows

	Commune 1	Appellation cour	Adresse 1	Siècle	Date de pro
	Marseille	Immeuble dit Maison du Figaro	1 cours Saint-Louis ; la	4e quart 17e siècle	1949/12/06 : insc MH
					1992/08/31 : clas MH ; 1994/09/02 inscrit MH
	Marseille	Maison dite de l'Echevin de Cabre	Grande-Rue 85	16e siècle	1926/11/02 : insc MH ; 1941/05/02 classé MH
	Marseille	Ancien atelier Nadar	77 La Canebière	4e quart 19e siècle	2012/02/20 : insc MH

Méthode 2 : en sélectionnant la colonne, *edit cells* et *replace*, permet de faire le changement grâce à un chercher-replacer

acteur	statut	Historique	Affectataire	Référence	Column	Column 16
ON	propriété d'une association		Facet	81361		
ecte)	propriété de l'Etat ; propriété privée	Une des premières implantations des Carmes en France. Rareté de l'architecture monastique troglodytique.	Text filter	81517		
	propriété privée		Edit cells			
	propriété d'une société privée	Seul atelier de Nadar subsistant et seul studio de photographe professionnel du 19e siècle	Edit column	PA130		
			Transpose			
			Sort...			
			View			
			Reconcile			

Méthode 3 : par une expression régulière, *edit cells*, *transform* puis saisir > `value.replace("direction générale des patrimoines", "Ministère de la Culture")`

OpenRefine demo_open_refine ods Permalink

Filter Undo / Redo 8 / 8 95 rows

Custom text transform on column Affectataire

Expression Language General Refine Expression Language (GREL) No syntax error.

`value.replace("direction générale des patrimoines", "Ministère de la Culture")`

Preview History Starred Help

row	value	value.replace("direction génér ...
1.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string
2.	ministère chargé de l'équipement et du logement	ministère chargé de l'équipement et du logement
3.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string
4.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string
5.	direction générale des patrimoines	Ministère de la Culture
6.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string
7.	null	Error: replace expects 3 strings, or 1 string, 1 regex, and 1 string

On error ☒ keep original ☐ set to blank ☐ store error ☐ Re-transform up to 10 times until no change

OK Cancel

Méthode 4 : par du rapprochement sémantique. Pour cela il faut choisir une autre colonne, par exemple *commune*

Séparer des colonnes

Choisir la colonne *Date de protection*, *split into several columns* et choisir les paramètres. Ne garder que la date dans la colonne.

Changer le type de champ

La colonne date peut être transformée en une véritable colonne de date : choisir la colonne, *edit cells, commons transforms, to date*

ls Show: 5 10 25 50 rows

Siècle	Date de protection	Type protection	Date de protection	Date de protection	Auteur	statut	Historique	
4e quart 17e siècle	Facet Text filter	scrit MH			PAVILLON Pierre (architecte)	propriété d'une association		
	Edit cells Edit column Transpose Sort... View Reconcile	Transform... Common transforms Fill down Blank down Split multi-valued cells... Join multi-valued cells... Cluster and edit... Replace	scrit			propriété de l'Etat ;	Une des premières implantations des Carmes en France. Rareté de l'architecture monastique troglodytique.	minis de l'é et du
16e siècle								
4e quart 19e siècle	2012/02/20	in					Seul atelier de Nadar subsistant et seul studio de photographe professionnel du 19e siècle connu en France à ce jour. Au terme d'une carrière parisienne de 40 ans et suite à une mésentente avec son fils Paul, Nadar (Gaspard Félix Tournachon 1820-1910 dit)	

Supprimer des espaces

Lors des changements précédents des espaces sont apparus en tête de champ, ils peuvent être supprimés : *edit cells*, *Trim leading and trailing whitespace*

Aller plus loin avec Open Refine

Open Refine peut appeler l'API de Wikidata, la base de données en web sémantique de Wikimedia. Il est ainsi possible de récupérer des éléments de Wikidata.

Par exemple, notre fichier comprend, pour certains monuments, un auteur. Si ces auteurs existent sur Wikidata, il est possible de rapatrier des informations, par exemple leur lieu de naissance.

Cette opération s'appelle une *réconciliation* de données.

Réconciliation des auteurs

Choisir la colone puis *reconcile*, *start reconciling* ajouter le service de réconciliation français

https://wikidata.reconci.link/fr/api (https://wikidata.reconci.link/fr/api)

de protectio	Type protection	Auteur	statut	Historique	Affectataire	Référence
06T00:00:00Z	inscrit MH	Facet Text filter				PA00081361
01T00:00:00Z	classé MH	Edit cells Edit column Transpose Sort... View		Une des premières implantations des Carmes en France. Rareté de l'architecture monastique troglodytique.	ministère chargé de l'équipement et du logement	PA00081517
02T00:00:00Z	inscrit MH	Reconcile				PA00081363
00T00:00:00Z	inscrit MH		propriété d'une société privée	Facets Actic Copy reconciliation data... Use values as identifiers Add entity identifiers column		PA13000075
				d'une carrière parisienne de 40 ans et suite à une		

La réconciliation porte sur des être humains, *start reconciling*

Reconcile column "Auteur"

» Access [Service API](#)

Reconcile each cell to an entity of one of these types:

☒ être humain
Q5

Also use relevant details from other columns:

Column	Include?	As Property
Commune	☐	
INSEE	☐	
Région	☐	
Département	☐	
Commune 1	☐	
Appellation courante	☐	
Adresse 1	☐	
Siècle	☐	
Date de protection 1 1	☐	
Type protection	☐	
statut	☐	
Historique	☐	

☐ Reconcile against type:

☐ Reconcile against no particular type

☒ Auto-match candidates with high confidence

Maximum number of candidates to return

Add Standard Service... Start Reconciling Cancel

Le système a fait le lien entre notre fichier et Wikidata, il propose une correspondance (matching), si cela correspond bien il faut le valider.

Auteur	statut	Historique	Affectataire	Référence	Column
PAVILLON Pierre (architecte) edit	propriété			PA00081361	

☒ [Pierre Pavillon](#) (73)

☒ Create new item

[Search for match](#)

Match this Cell Match All Identical Cells Cancel

[Pierre Pavillon](#) (Q15409315)

architecte français



l'architecture monastique troglodytique.

Alors ?

La qualité de la colonne ne permet pas de faire une bonne réconciliation.

Réconciliation à partir d'un identifiant

Tentons la réconciliation sur une autre colonne : *Référence*. Wikidata intègre de nombreux référentiel dont celui sur les identifiants des monuments historiques.

17 matching rows (95 total)

Show

ie

199

Reconcile column "Référence"

» Access [Service API](#)

Reconcile each cell to an entity of one of these types:

- ☐ maison
Q3947
- ☐ chapelle
Q108325
- ☐ château
Q751876
- ☐ cathédrale catholique
Q56242215
- ☐ immeuble
Q11755959
- ☐ église
Q16970
- ☐ grotte
Q35509
- ☐ atelier
Q656720
- ☐ forteresse
Q57831

Also use relevant details from other columns:

Column	Include?	As Property
Commune	☐	
INSEE	☐	
Région	☐	
Département	☐	
Commune 1	☐	
Appellation courante	☐	
Adresse 1	☐	
Siècle	☐	
Date de protection 1 1	☐	
Type protection	☐	
Auteur	☐	
statut	☐	

☒ Reconcile against type:

☐ Reconcile against no particular type

☒ Auto-match candidates with high confidence

Maximum number of candidates to return

Add Standard Service...

Start Reconciling Cancel

1996-10-03T00:00:00Z inscrit MH REY Sixte (architecte) propriété d'une Edifice construit pour le PA13000010

☒ Create new item

Cette fois cela fonctionne mieux, on peut ensuite récupérer les coordonnées géographiques des monuments, *add columns, add columns from reconciled values*

Permalink

5 rows

how as: rows

▼ Date de

1949-12-06T0

1992-08-31T0

1926-11-02T0

2012-02-20T0

Column ▼ Column 16

Add columns from reconciled column Référence

Add Property Preview Reset

coordonnées géographiques

Searching...

coordonnées géographiques P625

coordonnées géographiques de l'objet

identifiant GeoNames P1566

identifiant dans la base de données géographique GeoNames

identifiant Géopatronyme P3370

identifiant d'un nom de famille dans la base de données Géopatronym

géométrie géographique P3896

données géographiques de Wikimedia Commons

identifiant Geographical Names Board of New South Wales P3517

Identifiant sur le site web du Geographical Names Board of New Sou

identifiant du registre national géorgien des monuments P4166

identifiant pour un monument dans le registre national des monumen

identifiant George Eastman Museum P10018

identifiant d'une personne ou d'une organisation sur le site web du G

Référence	coordonnées géographiques
ro	43.2964,5.37806
des	43.3592,5.36194
	43.2975,5.37111
	43.297675,5.380574
te-Marie-	43.299444,5.364722
nitents blancs	43.297916666667,5.3687111111111
me-des-	43.29766667,5.36875
oulevard	43.274304,5.385904
uzine	43.2953,5.5025
	43.279861111111,5.3251388888889
6 quai du Port	43.296455,5.371056
	43.2744049,5.3635565
fort Saint-Jean	43.29472,5.3625
oppidum des Baou de Saint-Marcel	43.2992,5.46694
vieille Charité	43.300205,5.367774

OK Cancel

et réussit à en faire le rendez-

Joindre 2 fichiers

Il faut ouvrir les 2 fichier dans Open refine et en faire 2 projets

fichierA.csv — LibreOffice Calc

fichierB.csv — LibreOffice Calc

Fichier Édition Affichage Insertion

Fichier Édition Affichage Insertion Format Styles

Liberation Sans 10 Liberation Sans 10 pt G I

A1 Ville

	A	B	C
1	Ville	Info A	
2	Rouen	67	
3	Brest	98	
4	Marseille	34	
5	Paris	9	
6			
7			

	A	B	C	D
1	Ville	Info B		
2	Rouen	tomate		
3	Brest	courgette		
4	Marseille	poireau		
5	Paris	fenouil		
6				
7				

		Dernière modification ▼	Nom
✕	Détails	20 juin 2025, 15:07:41	fichierA.csv
✕	Détails	20 juin 2025, 14:59:41	fichierB.csv

Ensuite il faut ouvrir le projet A et “ajouter une colonne en fonction de cette colonne”, sur la colonne pivot (celle qui se trouve dans les 2 fichiers, dans mon exemple la ville)

4 lignes

Voir en: **lignes** entrées Afficher: 5 10 25 50 100 500 1000 lignes

Toutes

Ville

Info A

1. Facette

2. Filtrer le texte

3. Éditer les cellules

4. Éditer la colonne

Transposer

Trier...

Aperçu

Réconcilier

Diviser en plusieurs colonnes...

Joindre des colonnes...

Ajouter une colonne en fonction de cette colonne...

Ajouter une colonne en moissonnant des URL...

Et c'est là que GREL intervient 😊. Il faut saisir la fonction suivante, en indiquant le titre du projet, de la colonne pivot et de la colonne contenant les données à rapatrier

```
cell.cross("titre du projet B", "titre de la colonne pivot dans le projet B").cells["titre dans le projet B de la colonne contenant les données à rapatrier dans le projet A"].value[0]
```

4 lignes

Voir en: lignes entrées

Afficher: 5 10 25 50 100 500 1000 lignes

Toutes Ville Info A

1.	Rouen	67
2.	Brest	98
3.	Marseille	34
4.	Paris	9

Ajouter une colonne en fonction d'une colonne Ville

Nouveau nom de colonne Ajout info

En cas d'erreur

☒ vider la cellule
 ☐ conserver l'erreur
 ☐ copier la valeur depuis la colonne originale

Expression

Langue

General Refine Expression Language (GREL) ▾

cell.cross("fichierB csv", "Ville").cells["Info B"].value[0]

Pas d'erreur de syntaxe.

Aperçu Historique Étoilée Aide

row	value	cell.cross("fichierB csv", "Vi ...
1.	Rouen	tomate
2.	Brest	courgette
3.	Marseille	poireau
4.	Paris	fenouil

OK Annuler

Attention au nom de projet (si vous ne l'avez pas renommé) : mon fichier "fichierB.csv" est renommé automatiquement en projet "fichierB csv". Cela peut provoquer une erreur dans la fonction GREL

4 lignes

Voir en: lignes entrées

Afficher: 5 10 25 50

Toutes	Ville	Ajout info	Info A
1.	Rouen	tomate	67
2.	Brest	courgette	98
3.	Marseille	poireau	34
4.	Paris	fenouil	9